李龙宇

资深算法工程师 | 大模型端侧能效 / 模型压缩与量化 / 芯片软硬件协同

+86 18652989179 @ veyronmath@gmail.com 上海市杨浦区
github.com/yumath linkedin.com/in/yumath 南京大学硕士 · 6 年一线大厂研发经验



拥有 **6 年**模型压缩、高效推理与端侧能效研发经验，深耕 **大模型动态稀疏、端侧超低比特量化、知识蒸馏及 Agent 调优流水线**。曾先后任职于 **小米自研芯片部**、**华为诺亚方舟实验室** 与 **海思半导体**，主导多项大模型与视觉模型的小型化及千万级终端落地。具备从 **Megatron / ModelLink** 分布式训练调优到 **vDSP / NPU** 芯片底层部署的全栈能效优化能力，曾获华为 “研发工程能力提升奖”。

Experience

Ongoing – 2025.8 | **端侧低比特量化算法研发与精度恢复专项** | 小米 | 玄戒 - 多媒体算法

针对端侧芯片严苛的算力与功耗约束，主导视觉大模型 / ISP 底层算法的低比特量化研发，攻克高动态范围下的精度崩溃难题：

- **混合精度量化策略**：针对模型各层对量化噪声的异构敏感度，主导 INT8/INT16 混合精度搜索策略，在保证画质 PSNR/SSIM 损失 < 0.15 dB 前提下，实现模型极致压缩。
- **PTQ/QAT 算法攻坚**：研发基于敏感度分析的量化感知训练 (QAT) 与快速校准 (PTQ) 策略，设计自适应 Clipping 与误差补偿机制，有效解决离群点 (Outlier) 精度损失。
- **量化工具链研发**：打通模型分析、模拟量化到板端在环验证（HIL）的完整链路，实现多任务量化精度的快速自适应校准。

低比特量化 | 混合精度 | PTQ/QAT | 误差补偿 | 精度恢复 | 离群点抑制

Ongoing – 2025.8 | **端侧 vDSP 高性能模型部署与 Agent 自动化调优系统** | 小米 | 玄戒 - 多媒体算法

针对端侧芯片 vDSP 严苛的算力与内存带宽限制，主导视觉模型的底层压缩与极致部署，并落地 Agent 自动化调优流水线：

- **Agent 驱动的自动化调优**：构建面向 vDSP 的智能调优流水线，由 Agent 自动调度硬件 Profiling 工具、执行逐层敏感度分析与策略搜索，实现定点化精度与时延的**多目标自适应调优与自动化闭环**。
- **vDSP 平台定点化落地**：深入 vDSP 向量指令架构与片上缓存机制，主导定点化对齐、算子重组与访存带宽瓶颈（Memory-bound）优化，**达成极低时延的实时吞吐与超低功耗部署**。
- **模型压缩与画质保持**：针对高动态范围视觉特性，结合通道剪枝与自适应蒸馏，在严苛参数与 FLOPs 限制下，**最大化保留原始模型的画质与表征能力**。

Agent 自动化闭环 | vDSP 端侧部署 | 算子向量化 | 结构化剪枝 | 知识蒸馏 | 访存优化

2025.8 – 2023.12 | **LLM 动态稀疏方案研发与大规模训练** | 华为 | 诺亚方舟实验室 - 小模型实验室

针对端侧 Transformer 推理过程中的内存带宽瓶颈（Memory-bound），主导研发了基于激活稀疏的动态权重调整方案，有效降低 FFN 模块的内存搬运成本。

- **技术攻关**：通过激活函数替换与定制化算子优化，实现端侧硬件亲和的动态稀疏推理，显著加速 FFN 推理速度。针对 Pangu 模型设计验证了多种稀疏激活方案，在保证模型精度的同时最大化稀疏率。
- **架构设计**：在 SFT 阶段引入 Low Rank 稀疏 Predictor，基于 PEFT 框架实现高效的激活值稀疏化控制。
- **系统优化**：在昇腾平台上实现 Megatron 框架的深度定制，通过动态 Batch Loading 与 Domain 权重动态调整采样比例，**大幅提升预训练收敛速度**。代码成功迁移至 Ascend ModelLink 框架，支持多机多卡大规模预训练。
- **效果达成**：基于 DKD 算法实现 Dense 到 Sparse 模型的蒸馏，在 7B 模型上实现**精度损失 < 0.1% (PPL)**；通过 On-policy 蒸馏从模型生成的错误答案中学习，进一步提升了 SFT 模型的长序列建模能力。

模型剪枝 | **动态稀疏** | 昇腾算子优化 | Megatron 定制 | DKD 蒸馏

2023.12 – 2022.3 | **端侧模型高效推理与压缩基础设施 (CV/多模态)** | **华为 | 诺亚方舟实验室 - 小模型实验室**

主导多项 CV/多模态任务的模型小型化与压缩基础设施研发，涵盖剪枝、蒸馏、重参数化全流程：

- **通道对齐剪枝**：设计基于 Weight Normalization 参数共享的通道对齐剪枝法，并提出基于 L0 正则化的剪枝策略，**已申请华为公司技术秘密**。
- **端侧 Profile 与性能突破**：针对端侧时延进行底层 Profile 分析，设计硬件亲和 Attention 结构与高效算子替换（ONNX），**实现 4K 30fps 实时推理性能**。
- **非对称蒸馏与重参数化**：应用 Logits 蒸馏及非对称 Feature 蒸馏技术，结合 ECB 及 ExpandNet 重参数化结构，显著降低模型计算量。
- **规模化商业落地**：算法成功落地多款华为旗舰手机及海思芯片，并服务大华、天地伟业等核心行业客户。

结构化剪枝 | 重参数化 | 硬件亲和设计 | 4K 实时性能 | 技术秘密

2023.11 – 2023.4 | **高性能端侧量化与自监督优化专项** | **华为 | 诺亚方舟实验室 - 小模型实验室**

主导视觉大模型相关的端侧量化与自监督优化，算法作为核心亮点亮相华为旗舰手机发布会：

- **PoT 零成本量化**：应用 Power of Two (PoT) 量化方案，将 Scale 限制为移位操作，精细平衡 Rounding 与 Clipping 损失，**达成部署零成本加速，作为核心技术亮点亮相手机发布会**。
- **自监督学习**：设计对比学习自监督训练框架，通过模型自蒸馏有效抑制画质损伤；利用随机 Shift 构造自监督数据对，解决采样走样难题。
- **数据增强与鲁棒性**：通过 Ensemble 蒸馏构造正向数据，针对性优化伪影问题；对 Group-wise Conv 进行重参数化训练及参数合并，进一步提升模型鲁棒性。

PoT 量化 | 对比学习 | 自蒸馏 | 旗舰发布会亮点

2022.3 – 2020.9 | **C/C++系统级开发与性能优化** | **华为 | 海思半导体**

参与海思芯片系统的架构重构与内存精简工作，提升核心业务系统的稳定与效率：

- **架构重构**：基于 DCI 框架主导业务逻辑向 C++ 迁移，通过自研 DSL 语言实现业务与实现的深度解耦，独立实现 DSL 关键字并合入核心库。
- **性能精简与荣誉**：通过反汇编分析寻找内存痛点，主导系统级内存精简专项，显著降低芯片资源占用；**获评海思 “优秀新员工” 及 “芯星奖”，获华为软件可信专业级认证**。

DSL 设计 | DCI 架构 | C/C++性能优化 | 专业级认证 | 优秀员工

2019.7 – 2019.2 | **文本关键信息抽取与 NER 模型优化** | **南京大学**

- **模型研发与专利**：在 BiLSTM+CRF 结构中引入 Chinese-BERT-wwm，融合领域预训练与正则约束提升匹配精度，**F-1 值提升 2%，已授权国家发明专利一项**。
- **工程实践**：基于 Docker 实现环境自动化搭建，通过手工修改 CRF 状态转移矩阵引入规则约束，有效解决生产环境 Corner Case。

Chinese-BERT-wwm | NER 模型 | 知识融合 | 已授权专利 | Docker

Education

南京大学 — *2017.9 – 2020.7*

计算机技术 — **硕士**

中国矿业大学 (北京) — *2011.9 – 2015.7*

数学与应用数学 — **本科**

Projects

Bert NER ★ 450+ 90+ — github.com/yumath/BertNER — *2018 – 2019*

BERT 中文命名实体识别开源微调项目，结合 BiLSTM+CRF 结构，在社交媒体 Weibo NER 数据集上取得了 95.6% 的 F1-score。

BERT | BiLSTM+CRF | 预训练微调 | 知识蒸馏

Skills

核心专长	端侧大模型能效优化、模型压缩（剪枝 / 超低比特量化 / 知识蒸馏）、Agent 自动化调优
编程语言	C / **C++**（精通高性能系统重构与内存优化）、**Python**、Shell、CUDA
训练与框架	**PyTorch**、Megatron-LM、**ModelLink**、DeepSpeed、PEFT、Transformers、Accelerate
端侧与芯片	vDSP 定点化部署、Ascend CANN、ONNX / TensorRT、端侧高性能算子设计与访存优化